

# *Engenharia de Dados e Conhecimento*

## 2019/2020

### Expressão da Semântica

# *O Triplo* A Sua Formalização

Grafos

# Triplos



- No exemplo concreto, utilizado antes, que descreve Lugares, não existe nada no formato da tabela que restrinja o seu uso a locais com música e/ou que servem comida e bebidas.
- Na verdade, é perfeitamente possível representar factos acerca de outras entidades quaisquer no modelo chave-valor associado a IDs.
- O modelo de dados constituído por 3 campos é conhecido por triplo:
  - (ID – Propriedade – Valor)
  - Este consiste no bloco elementar e fundamental para implementar representações semânticas.

# Triplos



- O modelo triplo é formalmente definido por:
  - ( Sujeito – Predicado – Objeto )
- E possui os seguintes significados:
  - Sujeito = Entidade (Identificada por um ID)
    - uma "coisa" para a qual temos uma classe conceptual
    - exs: pessoas, lugares, objetos concretos, assim como coisas menos concretas, como períodos de tempo e ideias

# Triplos



- ... significados:
  - Predicado = Propriedade
    - uma propriedade da entidade, à qual está anexada
    - exs: nome de uma pessoa, data de nascimento, símbolo de uma ação no mercado de transações, endereços de email, etc.
  - Objeto = Valor (Entidade / Valor Literal)
    - os objetos podem ser de duas classes:
      - entidades, que por sua vez podem ser sujeitos noutros triplos
      - ou valores literais, como texto ou números.

# Grafos



- Utilizando os mesmos sujeitos e/ou os mesmos objetos, em diferentes triplos, é possível:
  - manter unidos múltiplos triplos, passando a ter uma teia de triplos;
  - representar as relações semânticas entre múltiplos dados.
- Esta teia de relações forma um **grafo** orientado.

# Grafos

- Flexibilizando o esquema particular anterior para que o ID da 1ª coluna represente qualquer entidade, obtemos:
  - Locais e vizinhanças no mesmo modelo.

| Subject | Predicate          | Object           |
|---------|--------------------|------------------|
| S1      | Cuisine            | "Deli"           |
| S1      | Price              | "\$"             |
| S1      | Name               | "Deli Llama"     |
| S1      | Address            | "Peachtree Rd"   |
| S2      | Cuisine            | "Chinese"        |
| S2      | Price              | "\$\$\$"         |
| S2      | Specialty Cocktail | "Scorpion Bowl"  |
| S2      | DJ?                | "No"             |
| S2      | Name               | "Peking Inn"     |
| S2      | Address            | "Lake St"        |
| S3      | Live Music?        | "Yes"            |
| S3      | Music Genre        | "Jazz"           |
| S3      | Name               | "Thai Tanic"     |
| S3      | Address            | "Branch Dr"      |
| S4      | Name               | "North Beach"    |
| S4      | Contained-by       | "San Francisco"  |
| S5      | Name               | "SOMA"           |
| S5      | Contained-by       | "San Francisco"  |
| S6      | Name               | "Gourmet Ghetto" |
| S6      | Contained-by       | "Berkeley"       |



# Grafos



- Na tabela anterior, as entidades não possuem ligação umas com as outras.
- Mas sabendo que é possível incluir sujeitos num triplo como objetos noutro triplo:
  - Podemos fazer:


| Subject | Predicate    | Object |
|---------|--------------|--------|
| S1      | Has Location | S4     |
| S2      | Has Location | S6     |
| S3      | Has Location | S5     |



# Grafos




- Diagrama representando um grafo com parte dos triplos das tabelas anteriores.



# O Exemplo “Movies”



- Uso do modelo de triplos para representar os dados relativos a filmes.
- Exemplo de um triplo:
  - (blade\_runner name “Blade Runner”)
    - blade\_runner = sujeito, ID que identifica o filme
    - name = predicado, propriedade do filme
    - “Blade Runner” = objeto, valor tipo texto da propriedade
  - Descreve o título de um filme.



# O Exemplo “Movies”



- De seguida, pretende-se declarar que o filme foi realizado por um determinado individuo.
  - Uma forma de o fazer:
    - (blade\_runner directed\_by “Ridley Scott”)
  - Esta forma tem 2 inconvenientes: o objeto, sendo um literal,
    - não pode ser sujeito noutros triplos o que não permite fazer declarações acerca do realizador
    - não identifica univocamente o realizador
  - O individuo “Ridley Scott” é uma pessoa e um realizador, entre mais coisas, o que o qualifica para ser uma entidade.

# O Exemplo “Movies”




- Se for atribuído o id “ridley\_scott” ao individuo, é então possível fazer as seguintes declarações:
  - (ridley\_scott name “Ridley Scott”)
  - (blade\_runner directed\_by ridley\_scott)
- É reutilizado o predicado nome, visto que este está a ser utilizado com o mesmo significado.
- Desta forma é implementado um triplo entre duas entidades em vez de uma entidade e um objeto.

# O Exemplo “Movies”



- Se adicionarmos ainda o triplo seguinte
  - (blade\_runner release\_date "June 25, 1982")
  - Obtemos o grafo seguinte:



# *TripleStore*

## Uma Implementação

## Filtragem

# Triplestore



- Uma *Triplestore* serve precisamente para guardar, gerir e pesquisar triplos de dados.
- Existem presentemente várias implementações de *triplestores* no mercado, contudo trabalhar com estas exige de imediato o domínio dos vários conceitos e padrões que compõem a web semântica.
- Presentemente, vamos recorrer a uma *triplestore* implementada em linguagem Python, que também ela possui vários toolkits para a programação da web semântica.
- Teremos assim a oportunidade de observar “por dentro” a sua construção.

# Uma Implementação



- Esta implementação é baseada em dicionários e faz a indexação cruzada dos três termos do triplo, por forma a permitir o acesso direto aos triplos através de qualquer dos termos.

- Índices

```
class SimpleGraph:
    def __init__(self):
        self._spo = {} # subject - predicate - object
        self._pos = {} # predicate - object - subject
        self._osp = {} # object - subject - predicate
```

- Um índice vai consistir num dicionário de dicionários que contem *sets*.

Ex:

```
self._spo = {subject:{predicate:set([object])}}
```

- Um *set* é uma lista não ordenada com elementos únicos.



# Uma Implementação



- O método `add()`
  - Adiciona todas as permutações dos termos do triplo a todos os índices.

```
def add(self, sub, pred, obj):  
    self._addToIndex(self._spo, sub, pred, obj)  
    ...
```

- O método `_addToIndex()`
  - Adiciona todos os termos do triplo ao índice, caso estes ainda não estejam presentes

```
def _addToIndex(self, index, a, b, c):  
    if a not in index:  
        index[a] = {b:set([c])}  
    ...
```

# Uma Implementação



- O método `remove()`
  - Remove o triplo de todos os índices

```
def remove(self, sub, pred, obj):  
    triples = list(self.triples(sub, pred, obj))  
    for (delSub, delPred, delObj) in triples:  
        self._removeFromIndex(self._spo, delSub, delPred, delObj)  
    ...
```

- O método `_removeFromIndex()`
  - Percorre o índice e limpa-o na remoção do triplo

```
def _removeFromIndex(self, index, a, b, c):  
    try:  
        bs = index[a]  
        cset = bs[b]  
        cset.remove(c)  
    ...
```

# Uma Implementação



- Filtragem de Triplos
  - Método triples() – filtra os triplos existentes, dado um triplo padrão
  - Os termos com valor “None”, assumem o valor “\*” (qualquer)

```
def triples(self, sub, pred, obj):  
    try:  
        if sub != None:  
            if pred != None:  
                # sub pred obj  
                if obj != None:  
                    if obj in self._spo[sub][pred]:  
                        yield (sub, pred, obj)  
                # sub pred None  
            else:  
                for retObj in self._spo[sub][pred]:  
                    yield (sub, pred, retObj)  
    ...
```

# Uma Implementação



- O método `load()`
  - Carrega os índices com triplos lidos de um ficheiro CSV

```
def load(self, filename):  
    f = open(filename, "r", newline="", encoding="utf-8")  
    reader = csv.reader(f)  
    for sub, pred, obj in reader:  
        self.add(sub, pred, obj)  
    f.close()
```

# Uma Implementação



- O método `save()`
  - Guarda todos os triplos num ficheiro CSV

```
def save(self, filename):  
    f = open(filename, "w", newline="", encoding="utf-8")  
    writer = csv.writer(f)  
    for sub, pred, obj in self.triples(None, None, None):  
        writer.writerow([sub, pred, obj])  
    f.close()
```

# *TripleStore*

## Uma Implementação

## Fusão de Grafos

# Fusão de Grafos





- A utilização de grafos na modelação de informação permite com facilidade a fusão entre múltiplos grafos diferentes.
  - Isto desde que estes possuam um sistema consistente de identificadores para os sujeitos e objetos.
  - Se um triplo se encontrar em mais que um grafo, os 2 triplos fundem-se de forma transparente, visto serem idênticos.
  - Isto é devido a que os nós e suas relações, nos grafos, são entidades de 1ª classe, isto é, são independentes e constituem “pedaços” de dados significativos.

# Fusão de Grafos



- Exemplo: grafos separados:






# Fusão de Grafos



- Exemplo: fusão dos grafos



# Fusão de Grafos



- Exemplo de uma função que recebe um grafo e faz a sua fusão com um grafo lido de um ficheiro:

```
def mergeFromFile(graph):  
    tmp = SimpleGraph()  
    tmp.load(input("Nome do ficheiro: "))  
    for sub, pred, obj in tmp.triples(None, None, None):  
        graph.add(sub, pred, obj)
```